

МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра МО ЭВМ

ОТЧЕТ
по лабораторной работе №4
по дисциплине «Построение и анализ алгоритмов»
Тема: Поиск подстроки в строке. (КМП)

Студент гр. 3388

Трунов Б.Г.

Преподаватель

Жангиров Т.Р.

Санкт-Петербург

2025

Цель работы:

Изучить принцип работы алгоритма Кнута-Морриса-Пратта для нахождения подстрок в строке. Решить с его помощью задачи.

Задание 1:

Реализуйте алгоритм КМП и с его помощью для заданных шаблона P ($|P| \leq 15000$) и текста T ($|T| \leq 5000000$) найдите все вхождения P в T .

Вход:

Первая строка - P

Вторая строка - T

Выход:

индексы начал вхождений P в T , разделенных запятой, если P не входит в T , то вывести -1

Sample Input:

ab

abab

Sample Output:

0,2

Задание 2:

Заданы две строки A ($|A| \leq 5000000$) и B ($|B| \leq 5000000$).

Определить, является ли A циклическим сдвигом B (это значит, что A и B имеют одинаковую длину и A состоит из суффикса B , склеенного с префиксом B). Например, defabc является циклическим сдвигом abcdef.

Вход:

Первая строка - A

Вторая строка - B

Выход:

Если A является циклическим сдвигом B , индекс начала строки B в A , иначе вывести -1 . Если возможно несколько сдвигов вывести первый индекс.

Sample Input:

defabc

abcdef

Sample Output:

3

Реализация

Описание алгоритма Кнута-Морриса-Пратта:

Алгоритм Кнута-Морриса-Пратта устраняет недостатки наивного поиска, где при несовпадении символов происходит возврат к началу подстроки и сдвиг на 1 символ. Вместо этого КМР использует префикс-суффикс функцию (LPS), чтобы определить, на сколько символов можно безопасно сдвинуть шаблон без потери потенциальных совпадений.

Шаги алгоритма:

- **Проверка соответствия размеров:**

- Если длина текста или длина шаблона равна 0, то возвращаем -1 в функции поиска и пустой массив в префикс-суффикс функции.
- Если длина шаблона больше длины текста, то аналогично возвращаем -1 в функции поиска и пустой массив в префикс-суффикс функции.
 - Для данного шага используется `_validate_data(text : str, pattern : str) -> bool`

- **Вычисление префикс-суффикс функции:**

- Создаётся массив длиной, равной длине шаблона, начальная инициализация нулями.
- Для каждого символа шаблона (начиная с индекса 1) определяется длина наибольшего префикса, который также является суффиксом.
- Далее используя два указателя `current_length` и `i` сравниваем символы шаблона и заполняем массив `LPS`.
 - Если `pattern[i]` равен `pattern[current_length]`, то `lps[i]=current_length`, и оба указателя увеличиваются на единицу.
 - Иначе два случая:
 - `current_length` не равен 0, тогда `current_length=lps[current_length - 1]`.

- *current_length* равен 0 тогда $lps[i] = 0$, указатель i увеличивается на единицу.
 - Для данного шага используется *_makeLongestPrefixSuffix(self)* -> *list[uint]*.
- **Поиск шаблона в тексте:**
 - Используются два указателя: i (для текста) и j (для шаблона).
 - Последовательно сравниваются символы текста и шаблона:
 - Совпадение:
 - Оба указателя сдвигаются вправо.
 - Несовпадение:
 - Если $j > 0$, указатель j сдвигается на $lps[j - 1]$.
 - Если j равен 0, указатель i сдвигается вправо на 1.
 - При полном совпадении (j равен длине шаблона) фиксируется позиция вхождения шаблона, а значение j корректируется через *lps*.
 - Для данного шага используется *_search(self)* -> *list[uint]*.

Оценка сложности алгоритма:

Временная сложность

Вычисление префикс-суффикс функции:

- Проход по шаблону длиной m : $O(m)$.
- Итог: $O(m)$.

Поиск:

- Проход по тексту длиной n : $O(n)$.
- Итог: $O(n)$.

Общая: $O(m+n)$

Пространственная сложность

Префикс-суффикс функция:

- lps : $O(m)$ для массива длиной m (длина шаблона).

Поиск:

- $result_search$: $O(k)$ для хранения индексов вхождений шаблона в текст, где $k \leq n$.

Итого: $O(m + k)$

Тестирование

Таблица 1. Тестирование.

| Входные данные | Выходные данные |
|--|---|
| Введите шаблон для поиска: 123 Введите текст для поиска: 123321123321123 Включить режим отладки? (y/n): n | Результат: Индексы вхождений шаблона в тексте: [0, 6, 12] |
| Введите шаблон для поиска: cppiscool Введите текст для поиска: cppiscoolcppiscoolcppisreallycoolcppiscoolcppcoolcoolcoocowcl Включить режим отладки? (y/n): n | Результат: Индексы вхождений шаблона в тексте: [0, 9, 33] |
| Введите шаблон для поиска: hello Введите текст для поиска: hello123321HELLOisYOOOOYAYAYA Включить режим отладки? (y/n): n | Результат: Индексы вхождений шаблона в тексте: [0] |
| Введите шаблон для поиска: Введите текст для поиска: 123 Включить режим отладки? (y/n): n | Результат: Совпадений не найдено |
| Введите шаблон для поиска: 123 Введите текст для поиска: Включить режим отладки? (y/n): n | Результат: Совпадений не найдено |
| Введите шаблон для поиска: 123 Введите текст для поиска: 12 Включить режим отладки? (y/n): n | Результат: Совпадений не найдено |

Вывод

В ходе выполнения лабораторной работы был изучен и успешно реализован алгоритм Кнута-Морриса-Пратта (КМП), предназначенный для эффективного поиска подстроки в тексте. Основным преимуществом этого алгоритма перед наивным подходом является исключение избыточных сравнений символов за счёт использования префикс-суффикс-функции (LPS), что позволяет снизить вычислительную сложность до линейной — $O(n + m)$, где n и m — длины текста и шаблона соответственно. Это достигается благодаря тому, что КМП избегает возвратов по тексту, делая его особенно полезным для обработки потоковых данных или работы с большими объёмами информации.